ITESO
Análisis Estadístico Multivariable
Otoño 2026
Prof. Luis Alvarado

ITESO, Universidad Jesuita de Guadalajara

Tarea 03 - Regresión Lineal y Logística con Dataset Titanic

Instrucciones:

Resuelva ***en equipo*** los siguientes ejercicios. **No se reciben trabajos fuera de la fecha establecida en la plataforma *Canvas*.**

- **Entregable: Archivo PDF**
  - El nombre del archivo será ‘‘`P4_E#Equipo_Nombre1_Nombre2.pdf`’’.
  - Ejemplo: ‘‘`P4_E1_Luis_Carlos.pdf`’’.

Entregable: Reporte que valide la realización de las actividades.

Especificaciones generales:

- El reporte del trabajo deberá ser un archivo PDF/HTML e incluirá como mínimo:
  - ✓ **Portada**.
  - ✓ **Introducción al dataset Titanic**.
  - ✓ **Análisis Exploratorio de Datos (EDA)**.
  - ✓ **Desarrollo: Regresión Lineal**.
  - ✓ **Desarrollo: Regresión Logística**.
  - ✓ **Conclusiones comparativas**.

  Nota: Incluir código (Python) como apéndice, gráficos de diagnóstico, tablas de resultados y interpretaciones detalladas, o desarrollarlo directamente en un notebook *.ipynb*

Contexto: Dataset Titanic

El dataset del Titanic contiene información sobre los pasajeros del transatlántico RMS Titanic, que se hundió el 15 de abril de 1912 tras chocar con un iceberg. Este dataset es ampliamente utilizado en análisis estadístico y machine learning porque:

- Contiene variables continuas y categóricas
- Tiene una variable respuesta binaria (Supervivencia: Sí/No)
- Permite explorar relaciones complejas entre múltiples predictores
- Ofrece datos reales y contexto histórico interesante

Variables principales:

- `Age`: Edad del pasajero (continua)
- `Fare`: Tarifa del pasaje (continua, en libras esterlinas)
- `Pclass`: Clase del pasaje (1, 2, 3 - categórica ordinal)
- `Sex`: Sexo del pasajero (Male/Female - categórica nominal)
- `Embarked`: Puerto de embarque (C, Q, S - categórica nominal)
- `Survived`: Supervivencia (0 = No, 1 = Sí - variable respuesta binaria)

PARTE 1: Regresión Lineal

Objetivo:

Construir un modelo de regresión lineal que prediga la **Edad** (`Age`) de los pasajeros del Titanic en función de la **Tarifa** (`Fare`) que pagaron.

Modelo: $\text{Age} = \beta_0 + \beta_1 \cdot \text{Fare} + \varepsilon$

Actividades a desarrollar:

1. **Análisis Exploratorio:**
   (a) Cargue el dataset Titanic (utilice `seaborn.load_dataset('titanic')` o una fuente similar)
   (b) Realice un análisis descriptivo de las variables `Age` y `Fare`:
      - Estadísticos descriptivos: media, mediana, desviación estándar, mín, máx, cuartiles
      - Identificar y reportar valores faltantes
   (c) Elabore gráficos exploratorios:
      - Histogramas con densidad para ambas variables
      - Gráfico de dispersión (scatter plot) entre `Fare` e `Age`
      - Matriz de correlación (al menos con otras variables numéricas relevantes)
   (d) Calcule el coeficiente de correlación de Pearson entre `Age` y `Fare`. Interprete su valor.
2. **Ajuste del Modelo:**
   (a) Ajuste el modelo de regresión lineal usando el método de **Máxima Verosimilitud (MLE)**
   (b) Reporte los coeficientes estimados: $\hat{\beta}_0$ (intercepto) y $\hat{\beta}_1$ (pendiente)
   (c) Presente la ecuación del modelo ajustado: $\hat{\text{Age}} = \hat{\beta}_0 + \hat{\beta}_1 \cdot \text{Fare}$

(d) Interprete los coeficientes en el contexto del problema:

- ¿Qué representa $\hat{\beta}_0$?
- ¿Qué significa el cambio en edad por cada libra adicional pagada?

3. **Inferencia Estadística:**

(a) **Pruebas de Hipótesis para los coeficientes:**

- Para β_0: ¿Es significativamente distinto de cero? $H_0 : \beta_0 = 0$ vs $H_1 : \beta_0 \neq 0$
- Para β_1: ¿Existe relación lineal significativa entre `Fare` e `Age`? $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$

(b) **Estadísticos de prueba:**

- Calcule el **t-value** para cada coeficiente: $t = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)}$
- Reporte el **Error Estándar (SE)** de cada estimador
- Determine los **grados de libertad** del modelo: $\text{df} = n - 2$

(c) **P-values:**

- Calcule el p-value para cada coeficiente (prueba bilateral, $\alpha = 0.05$)
- Interprete: ¿A qué nivel de significancia rechaza o no rechaza H_0?

(d) **Intervalos de Confianza al 95%:**

- Para β_0: $\hat{\beta}_0 \pm t_{n-2,0.025} \cdot \text{SE}(\hat{\beta}_0)$
- Para β_1: $\hat{\beta}_1 \pm t_{n-2,0.025} \cdot \text{SE}(\hat{\beta}_1)$
- Interprete los intervalos: ¿Qué nos dicen sobre el verdadero valor de los parámetros?

4. **Verificación de Supuestos:**

(a) **Supuesto 1: Linealidad**

- Gráfico: Residuos vs Valores Predichos. ¿Se observa una relación lineal? ¿Hay un patrón sistemático?
- Prueba RESET de Ramsey: Contraste H_0: La relación es lineal. Reportar estadístico y p-value.

(b) **Supuesto 2: Normalidad de Errores**

- Gráfico Q-Q Plot: ¿Los residuos siguen la diagonal? ¿Se desvían en las colas?
- Prueba Shapiro-Wilk: H_0: Los errores son normales. Reportar estadístico y p-value.
- Prueba Jarque-Bera: Complementaria para asimetría y curtosis. Reportar estadístico y p-value.
- Conclusión: ¿Se cumple el supuesto de normalidad?

(c) **Supuesto 3: Homocedasticidad (Varianza Constante)**

- Gráfico: Residuos vs Valores Predichos. ¿La dispersión es uniforme o hay patrón de embudo?
- Prueba de Breusch-Pagan: H_0: Varianza constante. Reportar estadístico y p-value.
- Conclusión: ¿Se cumple el supuesto de homocedasticidad?

(d) **Supuesto 4: Independencia de Errores**

- Estadístico de Durbin-Watson: Busque un valor cercano a 2 (rango: 0-4)
- Gráfico ACF (Autocorrelation Function): ¿Hay picos significativos?
- Conclusión: ¿Los errores son independientes?

5. **Métricas de Desempeño del Modelo:**

(a) **Coeficiente de Determinación (R^2):**

- Calcule: $R^2 = 1 - \frac{\text{SS}_{\text{res}}}{\text{SS}_{\text{tot}}}$
- Interpretación: ¿Qué porcentaje de la variabilidad en `Age` explica el modelo?

(b) **Coeficiente de Determinación Ajustado (R^2_{adj}):**

- Calcule: $R^2_{\text{adj}} = 1 - \frac{(1-R^2)(n-1)}{n-k-1}$ donde $k = 1$ predictor
- Comparación con R^2: ¿Cuál es más pequeño y por qué?

(c) **Error Cuadrático Medio (RMSE):**

- Calcule: $\text{RMSE} = \sqrt{\frac{\text{SS}_{\text{res}}}{n-2}}$
- Interpretación: ¿Cuál es el error promedio en la predicción de edad?

(d) **Error Absoluto Medio (MAE):**

- Calcule: $\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$

6. **Conclusiones de la Regresión Lineal:**

(a) Resuma los hallazgos principales: ¿Existe relación significativa entre tarifa y edad?

(b) ¿Se cumplen los supuestos del modelo? Si hay violaciones, ¿cuáles son las implicaciones?

(c) ¿Cuál es la confiabilidad del modelo para predicciones? Justifique con métricas de desempeño.

(d) ¿Qué mejoras sugeriría para futuros análisis?

PARTE 2: Regresión Logística

Objetivo:

Construir un modelo de regresión logística que prediga la **Probabilidad de Supervivencia** en función de múltiples predictores incluida la **Edad**.

Modelo: $P(\text{Survived} = 1|X) = \frac{1}{1+e^{-(\beta_0+\beta_1\cdot\text{Age}+\cdots)}}$

Especificación del Modelo:

Utilice los siguientes predictores (cree variables dummy para categóricas si es necesario):

- `Age`: Edad (continua)
- `Pclass`: Clase del pasaje (ordinal: 1, 2, 3)
- `Sex`: Sexo (categórica: Male=1, Female=0 o use dummies)
- `Fare`: Tarifa (continua)

Actividades a desarrollar:

1. **Preparación de Datos:**

(a) Imputación de valores faltantes:

- Para `Age`: Use la mediana por clase de pasaje (`Pclass`)
- Para `Fare`: Use la mediana general
- Para `Embarked`: Elimine registros o use la categoría más frecuente

(b) Codificación de variables categóricas:

- `Sex`: Cree variable binaria (Female=1, Male=0)
- Reporte antes/después

(c) Estandarización (opcional pero recomendado):

- Estandarice `Age` y `Fare` para comparabilidad de coeficientes
- Reporte media y desv. std. antes y después

2. **Ajuste del Modelo:**
   (a) Ajuste el modelo de regresión logística usando **Máxima Verosimilitud**
   (b) Reporte los coeficientes estimados: $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \ldots$
   (c) Presente el modelo ajustado con la ecuación logit:

$$\text{logit}(\hat{p}) = \hat{\beta}_0 + \hat{\beta}_1 \cdot \text{Age} + \cdots$$

   (d) Interprete los coeficientes en términos de **Odds Ratios**:
   - Calcule $\text{OR} = e^{\hat{\beta}_j}$ para cada coeficiente
   - Interpretación: ¿Qué cambio en los odds de supervivencia asocia cada incremento unitario del predictor?

3. **Inferencia Estadística:**
   (a) **Pruebas de Hipótesis de Wald:**
   - Para cada coeficiente β_j: $H_0 : \beta_j = 0$ vs $H_1 : \beta_j \neq 0$
   - El test de Wald en regresión logística utiliza: $W = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)}$

   (b) **Estadísticos de Wald:**
   - Calcule el **Wald z-value** para cada coeficiente: $z = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)}$
   - Reporte el **Error Estándar (SE)** de cada estimador

   (c) **P-values:**
   - Calcule el p-value para cada coeficiente (prueba bilateral: $p = 2 \cdot P(Z > |z|)$)
   - Interprete: ¿A nivel $\alpha = 0.05$, es el coeficiente significativo?

   (d) **Intervalos de Confianza al 95%:**
   - Para β_j: $\hat{\beta}_j \pm 1.96 \cdot \text{SE}(\hat{\beta}_j)$ (z-crítico = 1.96)
   - Interprete: ¿Incluye el IC el valor cero (o uno para OR)?

4. **Verificación de Supuestos (Adaptados para Logística):**
   (a) **Supuesto 1: No Colinealidad**
   - Calcule el **Variance Inflation Factor (VIF)** para cada predictor
   - Conclusión: ¿Hay problemas de colinealidad? (VIF $> 5 - 10$ indica problema)

   (b) **Supuesto 2: Linealidad en Logit**
   - Para variables continuas (`Age`, `Fare`): Gráfico de probabilidades predichas vs variable
   - Busque patrones no lineales

   (c) **Supuesto 3: Tamaño de Muestra y Casos Raros**
   - ¿Se cumple?

5. **Métricas de Desempeño del Modelo:**
   (a) **Matriz de Confusión y Métricas de Clasificación:**
   - Calcule la matriz de confusión con punto de corte $p = 0.5$
   - **Exactitud (Accuracy):** $\frac{\text{TP+TN}}{\text{Total}}$
   - **Sensibilidad (Recall/True Positive Rate):** $\frac{\text{TP}}{\text{TP+FN}}$ — ¿Qué % de supervivientes se predice?

- **Especificidad (True Negative Rate):** $\frac{TN}{TN+FP}$ — ¿Qué % de no supervivientes se predice?
- **Precisión (Positive Predictive Value):** $\frac{TP}{TP+FP}$ — De los predichos como supervivientes, ¿cuántos realmente lo son?

(b) **Curva ROC (Receiver Operating Characteristic):**

- Gráfico: Tasa de verdaderos positivos vs tasa de falsos positivos para distintos puntos de corte
- Calcule el **AUC (Area Under the Curve)**:
  - AUC = 0.5: El modelo no discrimina mejor que el azar
  - AUC = 1.0: Discriminación perfecta
  - Rango típico: 0.7-0.9 es aceptable

6. **Conclusiones de la Regresión Logística:**

(a) Resuma los hallazgos: ¿Cuáles son los predictores más significativos de supervivencia?

(b) Interprete los Odds Ratios: ¿Cuánto aumenta/disminuye el riesgo de supervivencia con cambios en los predictores?

(c) ¿Se cumplen los supuestos adaptados del modelo?

(d) ¿Cuál es el desempeño predictivo? (Accuracy, AUC, sensibilidad, especificidad)

(e) ¿Existe sesgo de clase o desbalance en los datos? ¿Afecta las predicciones?

(f) Recomendaciones: ¿Cómo mejorar el modelo? (variables adicionales, transformaciones, técnicas de balanceo)

PARTE 3: Análisis Comparativo

Comparación entre Regresión Lineal y Logística:

1. **Objetivos Diferentes:**

- Regresión Lineal: Predecir valor continuo (Edad)
- Regresión Logística: Predecir probabilidad/clasificación binaria (Supervivencia)
- ¿Cuál es más apropiado para cada pregunta de investigación?

2. **Supuestos y Validación:**

- ¿Cuáles supuestos se violaron en la regresión lineal? ¿Qué implicaciones tiene?
- ¿Se cumplieron mejor los supuestos adaptados en regresión logística?

3. **Interpretabilidad:**

- Comparar la interpretación de coeficientes: cambio unitario en RL vs Odds Ratios en RL
- ¿Cuál modelo es más fácil de explicar a un no-estadístico?

4. **Desempeño Predictivo:**

- En RL: RMSE, MAE, R^2
- En logística: Accuracy, AUC, Sensibilidad, Especificidad
- ¿Cuál modelo sería más útil en práctica? (contexto: Titanic)

Descarga y Carga del Dataset Titanic

Si ya tiene instalado `seaborn`, el dataset se descarga automáticamente:

```
# Importar librerías
import pandas as pd
import seaborn as sns
import numpy as np

# Descargar el dataset Titanic
titanic = sns.load_dataset('titanic')

# Verificar que se cargó correctamente
print("Dataset cargado exitosamente")
print(f"Dimensiones: {titanic.shape}")  # Debe mostrar (891, 15)
print("\nPrimeras filas:")
print(titanic.head())

# Ver información del dataset
print("\nInformación del dataset:")
print(titanic.info())

# Estadísticos descriptivos
print("\nEstadísticos descriptivos:")
print(titanic.describe())

# Ver valores faltantes
print("\nValores faltantes por columna:")
print(titanic.isnull().sum())
```

Nota: Si recibe error de conexión, puede descargar manualmente desde: https://raw.githubusercontent.com/mwaskom/sea
data/master/titanic.csv